Web Scraping con Beautiful Soup

Profesora: Belén Saldías Fuentes
Departamento de Ciencia de la Computación

Contenidos del curso: *Data Mining Stages*

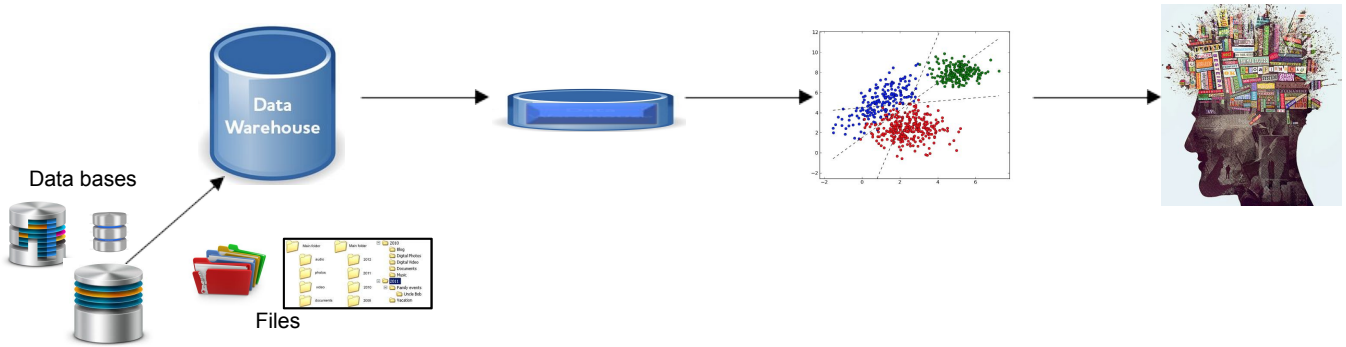

1. Data Integration
2. Data transformation and selection
3. Data Mining
4. Evaluation and visualization

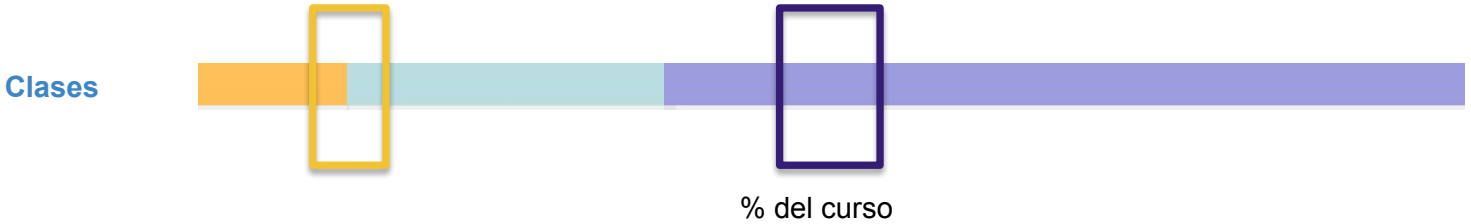

Mining the web!

- ¡Una de las **bases de datos** de texto no estructurado **más grandes del mundo**!
- Aplicación de minería de datos para **descubrir patrones en la Web**
- ***Clicking for gold*** → obtener ganancias utilizando los datos en la Web
- No siempre tenemos una API a la cual conectarnos

Source: https://www.emc.com/collateral/analyst-reports/ar-the-economist-data-data-everywhere.pdf

Datos en la Web - HTML5


```
1  <!DOCTYPE html>
2  <html>
3      <head>
4          <title>Example<title>
5          <link rel="stylesheet" href="sty
6      </head>
7      <body>
8          <h1>
9              <a href="/">Header</a>
10         </h1>
11         <nav>
12             <a href="one/">One</a>
13             <a href="two/">Two</a>
14             <a href="three/">Three</a>
15         </nav>
```

Tag de apertura

Tag de cierre

Elemento

Elementos semánticos de HTML5

- <header> </header>
- <nav> </nav>
- <section> </section>
- <article> </article>
- <aside> </aside>
- <figcaption> </figcaption>
- <figure> </figure>
- <footer> </footer>

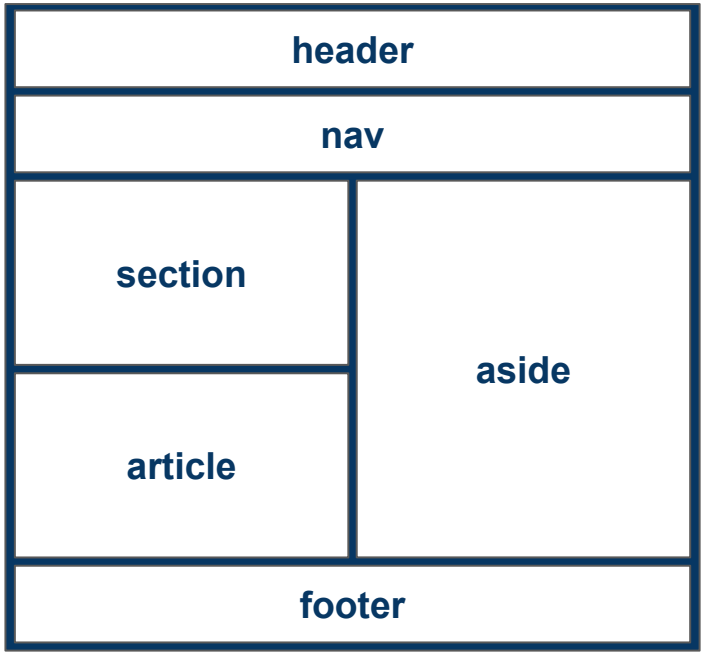

Source: https://es.slideshare.net/niharikagupta54966/html5ppt-25757426

Elementos a nivel de bloque

Estos elemento siempre comienzan en una nueva línea. Toman el ancho máximo disponible.

-
- <h1> </h1>
- ...
- <h6> </h6>
-
- <form> </form>

```
<!DOCTYPE html>
<html>
<body>

<div style="background-color:orange;color:white;padding:20px;">
  <h2>IIC2433 - Minería de datos</h2>
  <h4>Elementos a nivel de bloque</h4>
  <p>Estos elemento siempre comienzan en una nueva línea. Toman el ancho máximo disponible.</p>
  <p>Se cortan automáticamente en líneas para ajustarse al ancho de la pantalla. Dependiendo del
dispositivo es posible tomar cualquier tamaño máximo de ancho.</p>
</div>

</body>
</html>
```

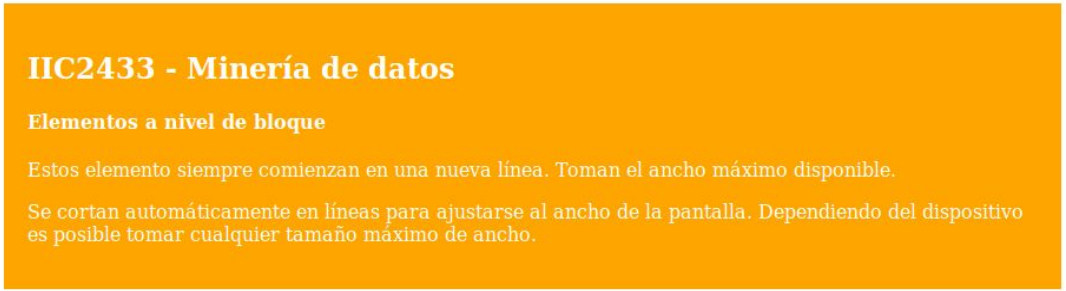

Source: https://www.w3schools.com/html/html_blocks.asp

Elementos en línea

No comienzan en una línea nueva. Toman solo el ancho necesario.

-
- <a>
- <img> </img>

```
<!DOCTYPE html>
<html>
<body>

<h1>IIC2433 - <span style="color:orange">Minería de Datos</span> - 2017/2</h1>

</body>
</html>
```

IIC2433 - Minería de Datos - 2017/2

Source: https://www.w3schools.com/html/html_blocks.asp

Web Scraping

- Técnica utilizada mediante programas de software para extraer información de sitios web.
- Usualmente se simula la navegación de un humano → **bot.**
- Se puede utilizar un protocolo HTTP para extraer los datos, o navegar y esperar que se cargue todo el sitio.

1. Beautiful soup

- ¿Qué es?
  - Librería para convertir documentos HTML en objetos
  - **Crea un árbol** con la estructura del HTML
  - Permite **extraer** información del árbol y consultarlo por **tags**

1. Beautiful soup

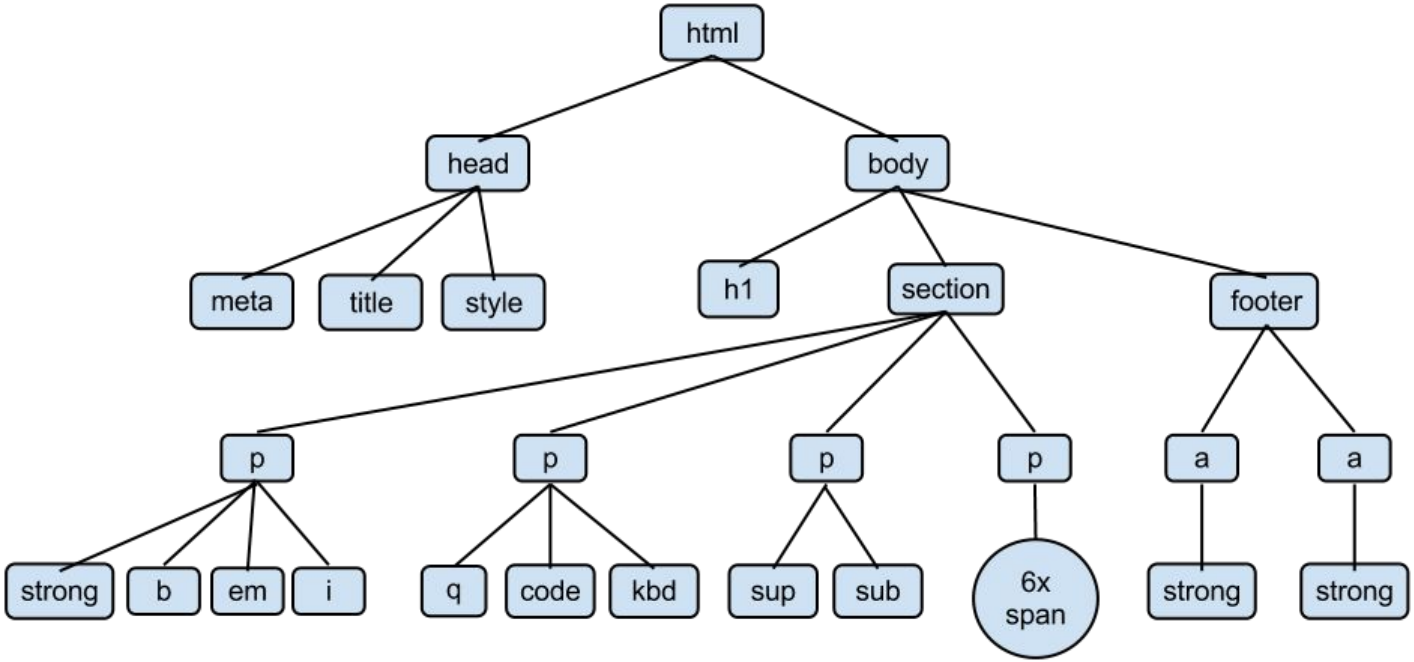

Source: http://www.openbookproject.net/tutorials/
http://web.stanford.edu/~zlotnick/TextAsData/Web_Scraping_with_Beautiful_Soup.html

1. Beautiful soup

```
# paquete que nos permite conectarnos (hacer un request) a un sitio web
import requests

# paquete para manipular el código html de una página web
from bs4 import BeautifulSoup

# paquete para manpular datos eficientemente
import pandas as pd
```

```
soup = BeautifulSoup(content, "html.parser")
```

- content puede ser un archivo HTML local o consultado en la Web

Source: http://www.openbookproject.net/tutorials/
http://web.stanford.edu/~zlotnick/TextAsData/Web_Scraping_with_Beautiful_Soup.html

1. Beautiful soup - comandos básicos

```
<html>
 <head>
  <title>
   The Dormouse's story
  </title>
 </head>

 <body>
  <p class="title">
   <b>
    The Dormouse's story
   </b>
  </p>
  <p class="story">
   Once upon a time there were three little sisters; and their names were
   <a class="sister" href="http://example.com/elsie" id="link1">
    Elsie
   </a>
   ,
   <a class="sister" href="http://example.com/lacie" id="link2">
    Lacie
   </a>
    ....
  </p>
  <p class="story">
   ...
  </p>
 </body>
</html>
```

```
> soup.title
<title>The Dormouse's story</title>
```

```
> soup.title.string
u'The Dormouse's story'
```

```
> soup.title.parent.name
u'head'
```

```
> soup.p
<p class="title"><b>The Dormouse's
story</b></p>
```

```
> soup.a
<a class="sister" href="http://example.com/elsie"
id="link1">Elsie</a>
```

```
> soup.find_all('a')
[<a class="sister" href="http://example.com/elsie"
id="link1">Elsie</a>,
 <a class="sister" href="http://example.com/lacie"
id="link2">Lacie</a>,
 <a class="sister" href="http://example.com/tillie"
id="link3">Tillie</a>]
```

```
> soup.find(id="link3")
<a class="sister" href="http://example.com/tillie"
id="link3">Tillie</a>
```

```
> for link in soup.find_all('a'):
>     print(link.get('href'))
http://example.com/elsie
http://example.com/lacie
http://example.com/tillie
```

2. Selenium

- ¿Qué es?
  - Automatiza navegadores.
  - Simula el comportamiento de un ser humano.
  - Generalmente usado para testing de sitios web.
  - ¡Puede ser usado para lo que sea! → **uso responsable**.

Source: http://www.seleniumhq.org/

Web Scraping con Beautiful Soup

Profesora: Belén Saldías Fuentes
Departamento de Ciencia de la Computación